

Mô hình đo lường biến động của tỷ lệ sinh lời giá chứng khoán

Chương 1 đã giới thiệu tỷ lệ sinh lời, các đặc điểm thống kê cơ bản của chuỗi tỷ lệ sinh lời tài chính và vai trò của phân phối trong đo lường rủi ro. Chương này chuyển trọng tâm sang **mức độ biến động của tỷ lệ sinh lời** (*return volatility*). Trong quản trị rủi ro thị trường, volatility là đại lượng trung tâm vì nó chi phối độ rộng của phân phối tỷ lệ sinh lời có điều kiện, qua đó ảnh hưởng trực tiếp đến dự báo VaR và Expected Shortfall [Choudhry2013; Tsay2013].

Volatility không quan sát trực tiếp như giá chứng khoán. Nhà phân tích chỉ quan sát được giá, từ đó tính tỷ lệ sinh lời, rồi ước lượng volatility bằng các phương pháp thống kê hoặc mô hình kinh tế lượng. Vì vậy, câu hỏi cốt lõi của chương là: **làm thế nào để đo lường và dự báo volatility theo cách phản ánh được đặc điểm của chuỗi tỷ lệ sinh lời tài chính?**

Chương được thiết kế theo logic từ đơn giản đến nâng cao. Mục 2.1 trình bày phương sai mẫu, độ lệch chuẩn mẫu và historical volatility. Mục 2.2 mở rộng sang rolling volatility, trong đó volatility được cập nhật bằng cửa sổ dữ liệu trượt. Mục 2.3 trình bày EWMA/RiskMetrics, tức một bước chuyển từ trọng số bằng nhau sang trọng số giảm dần theo thời gian. Mục 2.4 giới thiệu nhóm mô hình phương sai có điều kiện, gồm ARCH, GARCH và các biến thể quan trọng. Mục 2.5 bổ sung hai nhóm thước đo volatility khác: implied volatility và realized volatility. Các ví dụ trong chương sử dụng chuỗi tỷ lệ sinh lời mô phỏng để minh họa cơ chế mô hình. Việc áp dụng các mô hình này cho VN-Index và thị trường chứng khoán Việt Nam được trình bày trong Chương 3.

Mục tiêu của chương không phải là đưa ra kết luận thực nghiệm về một thị trường cụ thể, mà là giúp người đọc hiểu: mỗi phương pháp đo lường volatility được xây dựng như thế nào, sử dụng thông tin quá khứ ra sao, tham số có ý nghĩa gì, ưu điểm và hạn chế là gì, và khi nào nên chuyển từ mô hình đơn giản sang mô hình nâng cao. Cách tiếp cận này bám sát mạch trình bày trong các giáo trình kinh tế lượng tài chính ứng dụng như Tsay và Brooks [Tsay2010; Tsay2013; Brooks2019].

Table 1: Thông tin chuỗi tỷ lệ sinh lời mô phỏng sử dụng trong Chương 2

Nội dung	Thông tin
Loại dữ liệu	Chuỗi tỷ lệ sinh lời mô phỏng
Số quan sát	1.500
Cấu trúc volatility	Thay đổi theo bốn giai đoạn
Phân phối cú sốc	Student-t chuẩn hóa
Mục đích sử dụng	Minh họa cơ chế mô hình

Bảng Table 1 mô tả chuỗi tỷ lệ sinh lời mô phỏng được sử dụng trong chương. Chuỗi này không đại diện cho một thị trường cụ thể. Nó chỉ được thiết kế để thể hiện các đặc điểm thường gặp trong dữ liệu tài chính, như volatility thay đổi theo thời gian, quan sát cực đoan

và các giai đoạn rủi ro cao. Cách tiếp cận này giúp chúng tôi giữ vai trò là chương phương pháp, trước khi chuyển sang phân tích VN-Index trong Chương 3.

Mô hình đo lường mức độ biến động giản đơn

Điểm khởi đầu tự nhiên nhất trong đo lường volatility là phương sai và độ lệch chuẩn của tỷ lệ sinh lời. Cách tiếp cận này không đòi hỏi mô hình kinh tế lượng phức tạp, nhưng giữ vai trò nền tảng vì hầu hết các mô hình volatility hiện đại đều phát triển từ ý tưởng: mức độ biến động có thể được đo bằng quy mô dao động của tỷ lệ sinh lời quanh giá trị trung bình.

Giả sử ta có chuỗi tỷ lệ sinh lời $r_1, r_2, \dots, r_T$. Trung bình mẫu của tỷ lệ sinh lời là:

$$\bar{r} = \frac{1}{T} \sum_{t=1}^T r_t.$$

Phương sai mẫu được tính bằng:

$$s^2 = \frac{1}{T-1} \sum_{t=1}^T (r_t - \bar{r})^2.$$

Độ lệch chuẩn mẫu là căn bậc hai của phương sai mẫu:

$$s = \sqrt{s^2}.$$

Trong tài chính, độ lệch chuẩn của tỷ lệ sinh lời thường được gọi là **historical volatility** nếu được ước lượng từ dữ liệu quá khứ. Nếu chuỗi tỷ lệ sinh lời có tần suất ngày, độ lệch chuẩn mẫu phản ánh volatility bình quân theo ngày. Để quy đổi sang volatility năm, người ta thường dùng công thức:

$$\sigma_{\text{annual}} = \sigma_{\text{daily}} \sqrt{252}.$$

Con số 252 thường được sử dụng vì thị trường chứng khoán có khoảng 252 ngày giao dịch trong một năm. Tuy nhiên, quy tắc căn bậc hai của thời gian chỉ phù hợp dưới giả định tỷ lệ sinh lời độc lập, cùng phân phối và có phương sai không đổi. Đây là giả định mạnh. Khi dữ liệu có volatility clustering, tự tương quan trong bình phương tỷ lệ sinh lời hoặc thay đổi trạng thái thị trường, quy tắc này chỉ nên được xem là một xấp xỉ thực hành [Brooks2019; Tsay2013].

Volatility không điều kiện

Phương sai mẫu và độ lệch chuẩn mẫu đo mức biến động trung bình trong toàn bộ giai đoạn quan sát. Đây là cách tiếp cận **không điều kiện** (*unconditional volatility*), vì volatility được xem như một con số cố định cho cả chuỗi dữ liệu:

$$Var(r_t) = \sigma^2, \quad \forall t.$$

Cách tiếp cận này phù hợp khi mục tiêu là mô tả nhanh rủi ro trung bình của một tài sản hoặc tạo benchmark đơn giản trước khi dùng mô hình động. Hạn chế của nó là không phản ánh được sự thay đổi của rủi ro theo thời gian. Nếu chuỗi tỷ lệ sinh lời chuyển từ giai đoạn ổn định sang giai đoạn biến động cao, một con số volatility bình quân cho toàn mẫu sẽ phản ứng chậm và có thể làm sai lệch đánh giá rủi ro ngắn hạn.

Table 2: Volatility giản đơn của chuỗi tỷ lệ sinh lời mô phỏng

Chỉ tiêu	Giá trị
Trung bình mỗi kỳ	0,056%
Volatility mỗi kỳ	1,43%
Volatility năm hóa nếu dữ liệu là ngày	22,7%
Số quan sát	1.500

Bảng Table 2 cho thấy cách tính volatility giản đơn từ một chuỗi tỷ lệ sinh lời. Đây là bước khởi đầu cần thiết, nhưng không đủ để mô tả rủi ro thay đổi theo thời gian. Trong thực tế, một nhà quản trị rủi ro không chỉ cần biết volatility trung bình của cả giai đoạn, mà còn cần biết volatility hiện tại đang thấp, cao hay đang chuyển trạng thái.

Hình Figure 1 minh họa hạn chế của historical volatility. Khi dữ liệu có các giai đoạn biến động cao và thấp, một độ lệch chuẩn toàn mẫu chỉ cho biết mức rủi ro bình quân. Nó không cho biết thị trường đang ở trạng thái nào tại từng thời điểm.

Thước đo	Ý tưởng	Ưu điểm	Hạn chế
Phương sai mẫu Độ lệch chuẩn mẫu	Bình phương độ lệch Căn bậc hai phương sai	Nền tảng thống kê Dễ hiểu	Đơn vị khó diễn giải Giả định tĩnh
Historical volatility	Tính từ dữ liệu quá khứ	Benchmark đơn giản	Phản ứng chậm
Volatility không điều kiện	Một mức σ	Gọn, trực quan	Không xử lý clustering

Một volatility bình quân có thể che khuất các trạng thái rủi ro khác nhau

Đường ngang thể hiện historical volatility toàn mẫu; đường volatility thật chỉ có trong mô phỏng




Figure 1: Historical volatility không phản ánh đầy đủ biến động thay đổi theo thời gian

Mô hình trung bình trượt

Một cải tiến trực quan so với historical volatility toàn mẫu là chỉ sử dụng một cửa sổ dữ liệu gần hiện tại để ước lượng volatility. Đây là cách tiếp cận **trung bình trượt** hoặc **rolling window volatility**. Tại mỗi thời điểm t , nhà phân tích dùng m quan sát gần nhất:

$$r_{t-m+1}, r_{t-m+2}, \dots, r_t.$$

Rolling volatility tại thời điểm t được tính bằng:

$$\hat{\sigma}_t^2 = \frac{1}{m-1} \sum_{i=0}^{m-1} (r_{t-i} - \bar{r}_{t,m})^2,$$

trong đó:

$$\bar{r}_{t,m} = \frac{1}{m} \sum_{i=0}^{m-1} r_{t-i}.$$

Với dữ liệu tỷ lệ sinh lời ngày, trung bình ngắn hạn thường nhỏ hơn volatility. Vì vậy, trong một số ứng dụng quản trị rủi ro, phương sai rolling có thể được xấp xỉ bằng trung bình các squared returns:

$$\hat{\sigma}_t^2 \approx \frac{1}{m} \sum_{i=0}^{m-1} r_{t-i}^2.$$

Công thức trên cho thấy rolling volatility vẫn là một mô hình đơn giản: mọi quan sát trong cửa sổ đều có trọng số bằng nhau. Quan sát xảy ra ở kỳ gần nhất và quan sát xảy ra ở kỳ đầu tiên của cửa sổ có cùng ảnh hưởng đến volatility hiện tại. Ngược lại, quan sát vừa rơi ra khỏi cửa sổ lập tức mất toàn bộ ảnh hưởng.

Lựa chọn độ dài cửa sổ

Tham số quan trọng nhất của rolling volatility là độ dài cửa sổ m . Cửa sổ ngắn phản ứng nhanh với thông tin mới, nhưng đường volatility thường nhiễu. Cửa sổ dài tạo ra đường volatility mượt hơn, nhưng phản ứng chậm khi thị trường chuyển trạng thái. Do đó, rolling volatility luôn đi kèm một đánh đổi giữa **độ nhạy** và **độ mượt**.

Nếu dữ liệu là ngày giao dịch, cửa sổ 20 kỳ thường tương ứng khoảng một tháng, 60 kỳ tương ứng khoảng một quý, còn 120 hoặc 252 kỳ tương ứng giai đoạn dài hơn. Tuy nhiên, trong chương này, các cửa sổ này chỉ được dùng như ví dụ minh họa. Khi áp dụng cho dữ liệu thật

trong Chương 3, việc chọn cửa sổ cần gắn với mục tiêu dự báo, tần suất dữ liệu và đặc điểm thị trường.




Figure 2: Rolling volatility với các độ dài cửa sổ khác nhau

Hình Figure 2 cho thấy rolling volatility giúp mô hình phản ứng tốt hơn so với historical volatility toàn mẫu. Tuy nhiên, các đường rolling vẫn bị chi phối mạnh bởi lựa chọn cửa sổ. Cửa sổ 20 kỳ theo sát thay đổi hơn, nhưng biến động nhiều. Cửa sổ 120 kỳ mượt hơn, nhưng có độ trễ rõ rệt.

Hạn chế của trọng số bằng nhau

Điểm yếu cốt lõi của rolling volatility là **equal weighting**. Nếu dùng cửa sổ 60 kỳ, cú sốc ở kỳ $t - 1$ và cú sốc ở kỳ $t - 60$ có cùng trọng số. Trong khi đó, cú sốc ở kỳ $t - 61$ không còn vai trò gì. Cách xử lý này có thể tạo ra hai vấn đề. Một là volatility phản ứng chậm nếu cửa sổ dài. Hai là volatility có thể thay đổi đột ngột khi một quan sát cực đoan rơi khỏi cửa sổ.

EWMA khắc phục một phần hạn chế này bằng cách gán trọng số giảm dần theo thời gian. Đây là nội dung của mục tiếp theo.

Mô hình trung bình trượt với trọng số thay đổi

Mô hình trung bình trượt với trọng số thay đổi cho phép các quan sát gần hiện tại có ảnh hưởng lớn hơn các quan sát xa trong quá khứ. Cách tiếp cận phổ biến nhất là **Exponentially Weighted Moving Average** (EWMA), gắn với khuôn khổ RiskMetrics [RiskMetrics1996; Brooks2019].

EWMA cập nhật phương sai hiện tại từ phương sai quá khứ và cú sốc mới nhất:

$$\hat{\sigma}_t^2 = \lambda \hat{\sigma}_{t-1}^2 + (1 - \lambda) r_{t-1}^2,$$

trong đó $0 < \lambda < 1$ là hệ số suy giảm (*decay factor*). Nếu λ lớn, volatility quá khứ được duy trì lâu hơn và mô hình phản ứng chậm hơn với cú sốc mới. Nếu λ nhỏ, cú sốc mới có trọng số lớn hơn và mô hình phản ứng nhanh hơn.

Khi khai triển đệ quy, EWMA có thể viết dưới dạng trung bình có trọng số của các squared returns trong quá khứ:

$$\hat{\sigma}_t^2 = (1 - \lambda) \sum_{j=1}^{\infty} \lambda^{j-1} r_{t-j}^2.$$

Công thức này cho thấy trọng số của cú sốc quá khứ giảm theo cấp số nhân. Quan sát càng xa hiện tại thì trọng số càng nhỏ. Đây là khác biệt cơ bản giữa EWMA và rolling volatility.

Decay factor và half-life

Một cách trực quan để hiểu λ là thông qua **chu kỳ bán rã** (*half-life*), tức số kỳ cần để trọng số của một cú sốc giảm còn một nửa:

$$HL = \frac{\log(0.5)}{\log(\lambda)}.$$

Nếu $\lambda = 0.94$, half-life xấp xỉ 11 kỳ. Nghĩa là sau khoảng 11 kỳ, ảnh hưởng của một cú sốc đến volatility EWMA giảm còn một nửa. Giá trị λ càng lớn, ký ức của mô hình về cú sốc càng dài.

Table 3: Half-life tương ứng với một số giá trị lambda

Lambda	Half-life, kỳ
0.90	6.6
0.94	11.2
0.97	22.8

Table 3: Half-life tương ứng với một số giá trị lambda

Lambda	Half-life, kỳ
--------	---------------

Bảng Table 3 và Hình Figure 3 cho thấy vai trò của decay factor. EWMA phản ứng linh hoạt hơn moving average có trọng số bằng nhau, nhưng vẫn đơn giản hơn GARCH vì không cần ước lượng nhiều tham số.

EWMA như bước đệm tới GARCH

EWMA có thể được xem như một bước đệm từ rolling volatility sang mô hình GARCH. Nó đã đưa vào ý tưởng volatility có điều kiện và cập nhật theo thông tin quá khứ. Tuy nhiên, EWMA không có thành phần hằng số và không có mức phương sai dài hạn rõ ràng. Vì vậy, EWMA không mô tả cơ chế mean reversion theo cách GARCH thực hiện.

Hình Figure 4 cho thấy EWMA tạo ra đường volatility liên tục hơn rolling volatility. Tuy nhiên, EWMA vẫn chưa phải là mô hình kinh tế lượng đầy đủ cho phương sai có điều kiện. GARCH mở rộng logic này bằng cách cho volatility hiện tại phụ thuộc đồng thời vào cú sốc mới và chính volatility quá khứ.

Mô hình phương sai có điều kiện

Các phương pháp historical volatility, rolling volatility và EWMA đều có giá trị thực hành, nhưng chúng chưa mô hình hóa đầy đủ cơ chế tạo ra volatility. Nhóm mô hình phương sai có điều kiện đặt volatility vào một cấu trúc kinh tế lượng rõ ràng. Ý tưởng cốt lõi là phương sai tại thời điểm t phụ thuộc vào thông tin có sẵn tại thời điểm $t - 1$.

Một cấu trúc chung có thể viết như sau:

$$r_t = \mu_t + \varepsilon_t,$$

$$\varepsilon_t = \sigma_t z_t,$$

trong đó μ_t là kỳ vọng có điều kiện, ε_t là cú sốc không dự báo được, σ_t^2 là phương sai có điều kiện, còn z_t là sai số chuẩn hóa với $E(z_t) = 0$ và $Var(z_t) = 1$. Trong dữ liệu tỷ lệ sinh lời ngày, phương trình trung bình thường đơn giản, còn trọng tâm phân tích nằm ở phương trình phương sai [Engle1982; Bollerslev1986; Tsay2010; Brooks2019].




Figure 3: Trọng số EWMA giảm dần theo thời gian

EWMA cập nhật volatility liên tục hơn rolling volatility

Lambda nhỏ phản ứng nhanh hơn; lambda lớn duy trì ảnh hưởng của cú sốc lâu hơn




Figure 4: So sánh rolling volatility và EWMA volatility

Kiểm định ARCH effect

Trước khi sử dụng mô hình ARCH/GARCH, cần kiểm tra xem chuỗi tỷ lệ sinh lời có bằng chứng về phương sai có điều kiện thay đổi theo thời gian hay không. Một kiểm định phổ biến là ARCH-LM. Với phần dư $\hat{\varepsilon}_t$ từ phương trình trung bình, ta hồi quy:

$$\hat{\varepsilon}_t^2 = a_0 + a_1 \hat{\varepsilon}_{t-1}^2 + a_2 \hat{\varepsilon}_{t-2}^2 + \dots + a_m \hat{\varepsilon}_{t-m}^2 + v_t.$$

Giả thuyết không là không có ARCH effect đến bậc m :

$$H_0 : a_1 = a_2 = \dots = a_m = 0.$$

Nếu bác bỏ H_0 , chuỗi có bằng chứng về phương sai thay đổi có điều kiện. Khi đó, việc sử dụng ARCH/GARCH có cơ sở thực nghiệm.

Table 4: Kiểm định ARCH-LM cho chuỗi tỷ lệ sinh lời mô phỏng

Kiểm định	Số độ trễ	Thống kê	p-value
ARCH-LM	12	70.377	0

Bảng Table 4 minh họa cách kiểm định ARCH effect. Trong ứng dụng thực tế, kiểm định này cần được thực hiện trên tỷ lệ sinh lời hoặc phần dư từ phương trình trung bình trước khi lựa chọn mô hình GARCH.

Mô hình ARCH

Mô hình **Autoregressive Conditional Heteroskedasticity** bậc q , ký hiệu $ARCH(q)$, giả định phương sai có điều kiện phụ thuộc vào bình phương cú sốc trong quá khứ:

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_q \varepsilon_{t-q}^2.$$

Để đảm bảo phương sai dương, các ràng buộc thường dùng là:

$$\omega > 0, \quad \alpha_i \geq 0.$$

ARCH có diễn giải kinh tế trực quan: cú sốc lớn trong quá khứ làm volatility hiện tại tăng lên. Nói cách khác, “tin tức” hôm nay thay đổi volatility ngày mai. Đây là lý do ARCH giải thích được volatility clustering: ngày biến động mạnh thường đi sau ngày biến động mạnh.

Tuy nhiên, ARCH có hạn chế. Trong nhiều chuỗi tài chính, volatility có tính dai dẳng cao. Nếu chỉ dùng ARCH, nhà phân tích có thể cần bậc q lớn để mô tả persistence. Khi đó số tham số tăng, mô hình trở nên cồng kềnh và khó ước lượng ổn định. GARCH được phát triển để khắc phục hạn chế này.

Mô hình GARCH

Mô hình **Generalized ARCH**, ký hiệu $\text{GARCH}(p, q)$, mở rộng ARCH bằng cách đưa thêm phương sai có điều kiện quá khứ vào phương trình volatility:

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2.$$

Trong thực nghiệm, mô hình $\text{GARCH}(1,1)$ được sử dụng rất phổ biến:

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2.$$

Tham số α_1 đo mức phản ứng tức thời của volatility trước cú sốc mới. Tham số β_1 đo độ bền của volatility quá khứ. Tổng $\alpha_1 + \beta_1$ phản ánh **persistence of volatility**. Nếu tổng này gần 1, cú sốc volatility mất nhiều thời gian để triệt tiêu.

Với $\text{GARCH}(1,1)$, điều kiện thường dùng để phương sai không điều kiện hữu hạn là:

$$\alpha_1 + \beta_1 < 1.$$

Khi điều kiện này thỏa mãn, phương sai dài hạn là:

$$E(\sigma_t^2) = \frac{\omega}{1 - \alpha_1 - \beta_1}.$$

Đây là điểm phân biệt quan trọng giữa GARCH và EWMA. EWMA không có mức phương sai dài hạn rõ ràng; GARCH có cơ chế quay về mức volatility dài hạn nếu quá trình là dừng.

Forecasting volatility trong GARCH

Một ưu điểm lớn của GARCH là mô hình cung cấp công thức dự báo volatility. Với GARCH(1,1), dự báo phương sai một bước tới có dạng:

$$\hat{\sigma}_{t+1|t}^2 = \hat{\omega} + \hat{\alpha}\hat{\varepsilon}_t^2 + \hat{\beta}\hat{\sigma}_t^2.$$

Dự báo nhiều bước tới sẽ dần tiến về phương sai dài hạn nếu $\hat{\alpha} + \hat{\beta} < 1$. Do đó, GARCH không chỉ là mô hình đo lường volatility trong mẫu, mà còn là mô hình dự báo volatility có cơ chế mean reversion. Đây là lý do GARCH thường được sử dụng trong VaR động, định giá phái sinh và quản trị rủi ro thị trường [Tsay2010; Brooks2019].

Table 5: Minh họa ước lượng GARCH(1,1)-Student-t trên chuỗi mô phỏng

Tham số	Ước lượng
mu	0.000282
omega	0.000002
alpha1	0.057830
beta1	0.938079
shape	5.003006

Bảng Table 5 chỉ có mục tiêu minh họa cách đọc tham số. Trong ứng dụng thực nghiệm, việc diễn giải cần kết hợp dấu, độ lớn, ý nghĩa thống kê, diagnostics phần dư và khả năng dự báo ngoài mẫu.

Hình Figure 5 minh họa ý tưởng chính: volatility có điều kiện thay đổi theo thời gian và phản ứng với các cú sốc của tỷ lệ sinh lời. Trong dữ liệu thực, đường volatility thật không quan sát được; trong mô phỏng, nó giúp kiểm tra trực quan mô hình học được gì từ dữ liệu.

Các biến thể của mô hình GARCH

GARCH chuẩn là mô hình nền, nhưng dữ liệu tài chính thường có các đặc điểm mà GARCH chuẩn không xử lý đầy đủ. Do đó, nhiều biến thể GARCH được phát triển để mô tả persistence cực cao, quan hệ rủi ro-lợi suất, bất đối xứng và đuôi dày [Tsay2010; Brooks2019].

Biến thể	Ý tưởng chính	Khi nên cân nhắc
IGARCH	Persistence gần đơn vị	Cú sốc volatility rất dai dẳng
GARCH-M	Volatility đi vào mean	Kiểm tra risk premium
EGARCH	Log variance	Bất đối xứng, không cần ràng buộc dương
GJR/TGARCH	Biến chỉ báo shock âm	Leverage effect

Biến thể	Ý tưởng chính	Khi nên cân nhắc
APARCH	Lũy thừa volatility linh hoạt	Phản ứng phi tuyến

IGARCH là trường hợp đặc biệt trong đó $\alpha + \beta = 1$. Khi đó, cú sốc volatility có tác động rất dai dẳng và mô hình không có phương sai dài hạn hữu hạn theo nghĩa thông thường. EWMA có thể được xem như một dạng IGARCH hạn chế vì phương trình EWMA không có thành phần hằng số và trọng số được quyết định bởi một decay factor cố định.

Các mô hình EGARCH, TGARCH, GJR-GARCH và APARCH xử lý vấn đề bất đối xứng. Chúng đặc biệt quan trọng với thị trường cổ phiếu, nơi cú sốc âm thường làm volatility tăng mạnh hơn cú sốc dương có cùng độ lớn tuyệt đối. Đây là nội dung được trình bày kỹ hơn ở mục 2.4.6.

Mô hình GARCH với các phân phối xác suất

Trong mô hình GARCH, ta cần giả định phân phối cho sai số chuẩn hóa z_t . Lựa chọn đơn giản nhất là phân phối chuẩn. Tuy nhiên, tỷ lệ sinh lời tài chính thường có đuôi dày và có thể bất đối xứng. Nếu vẫn dùng phân phối chuẩn, mô hình có thể đánh giá thấp xác suất xảy ra cú sốc cực đoan. Điều này đặc biệt quan trọng khi volatility forecast được dùng làm đầu vào cho VaR [Tsay2010; Brooks2019].

Trong `rugarch`, một số phân phối thường dùng gồm:

Ký hiệu	Phân phối	Đặc điểm
<code>norm</code>	Gaussian	Mô hình nền
<code>std</code>	Student-t	Đuôi dày
<code>sstd</code>	Skewed Student-t	Đuôi dày và lệch
<code>ged</code>	Generalized Error	Độ dày đuôi linh hoạt
<code>sged</code>	Skewed GED	Lệch và đuôi linh hoạt

Việc chọn phân phối không chỉ ảnh hưởng đến log-likelihood, AIC/BIC hoặc phần dư chuẩn hóa, mà còn ảnh hưởng trực tiếp đến phân vị được dùng trong VaR. Vì vậy, trong thực nghiệm, GARCH-normal thường được dùng như benchmark, còn GARCH-Student-t hoặc GARCH-skewed-t thường được cân nhắc khi dữ liệu có kurtosis cao hoặc đuôi trái dày.

Mô hình GARCH-M

Mô hình GARCH-in-Mean đưa volatility vào phương trình trung bình. Một dạng thường dùng là:




Figure 5: Volatility có điều kiện từ mô hình GARCH(1,1)-Student-t

$$r_t = \mu + \delta \sigma_t^2 + \varepsilon_t,$$

hoặc:

$$r_t = \mu + \delta \sigma_t + \varepsilon_t.$$

Tham số δ được diễn giải như phần bù rủi ro. Nếu $\delta > 0$, volatility cao hơn gắn với tỷ lệ sinh lời kỳ vọng cao hơn. Ý tưởng này phù hợp với trực giác tài chính: tài sản rủi ro hơn cần có phần bù rủi ro cao hơn. Tuy nhiên, trong dữ liệu tần suất ngày, quan hệ giữa volatility và tỷ lệ sinh lời kỳ vọng thường yếu, không ổn định và nhảy với đặc điểm mẫu. Do đó, GARCH-M nên được xem là mô hình mở rộng để kiểm tra giả thuyết risk–return tradeoff, không phải mô hình nền cho mọi bài toán volatility.

Mô hình GARCH với hiệu ứng chệch của biến động

Một đặc điểm thực nghiệm quan trọng của thị trường cổ phiếu là **leverage effect**: cú sốc âm thường làm volatility tăng mạnh hơn cú sốc dương có cùng độ lớn tuyệt đối. GARCH chuẩn không xử lý được hiện tượng này vì nó sử dụng ε_{t-1}^2 , tức cú sốc dương và âm có cùng độ lớn sẽ có cùng ảnh hưởng.

EGARCH mô hình hóa log phương sai có điều kiện [Nelson1991]:

$$\log(\sigma_t^2) = \omega + \beta \log(\sigma_{t-1}^2) + \alpha \left(\frac{|\varepsilon_{t-1}|}{\sigma_{t-1}} - E|z_t| \right) + \gamma \frac{\varepsilon_{t-1}}{\sigma_{t-1}}.$$

Vì mô hình làm việc với log variance, σ_t^2 luôn dương. Tham số γ cho phép phản ứng bất đối xứng. Nếu $\gamma < 0$, cú sốc âm làm volatility tăng mạnh hơn cú sốc dương.

GJR-GARCH đưa biến chỉ báo shock âm vào phương trình phương sai [Glosten1993]:

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \gamma \varepsilon_{t-1}^2 I(\varepsilon_{t-1} < 0) + \beta \sigma_{t-1}^2.$$

Nếu $\gamma > 0$, shock âm làm volatility tăng mạnh hơn shock dương. TGARCH có logic tương tự nhưng thường được viết theo phương trình độ lệch chuẩn thay vì phương sai [Zakoian1994]. APARCH tổng quát hóa thêm bằng cách cho phép lũy thừa của volatility được ước lượng từ dữ liệu [Ding1993]:

$$\sigma_t^\delta = \omega + \alpha (|\varepsilon_{t-1}| - \gamma \varepsilon_{t-1})^\delta + \beta \sigma_{t-1}^\delta.$$

Mô hình bất đối xứng cho phép shock âm làm volatility tăng mạnh hơn

Với GARCH chuẩn, shock dương và âm cùng độ lớn có tác động như nhau; với GJR-GARCH, shock âm có tác động mạnh hơn shock dương.




Figure 6: News impact curve của GARCH chuẩn và GJR-GARCH

Hình Figure 6 minh họa khác biệt giữa GARCH chuẩn và mô hình bất đối xứng. Đây là lý do trong thực nghiệm với thị trường cổ phiếu, nhà phân tích thường so sánh GARCH với GJR-GARCH hoặc EGARCH thay vì chỉ dùng một mô hình chuẩn duy nhất.

Chẩn đoán mô hình GARCH

Sau khi ước lượng GARCH, không nên chỉ nhìn vào hệ số. Cần kiểm tra phần dư chuẩn hóa:

$$\hat{z}_t = \frac{\hat{\varepsilon}_t}{\hat{\sigma}_t}.$$

Nếu mô hình phù hợp, $\hat{z}_t$ không nên còn tự tương quan rõ rệt, và $\hat{z}_t^2$ không nên còn ARCH effect đáng kể. Các kiểm định thường dùng gồm Ljung–Box trên $\hat{z}_t$, Ljung–Box trên $\hat{z}_t^2$, ARCH-LM trên phần dư chuẩn hóa, Q–Q plot và các tiêu chí thông tin như AIC/BIC. Chẩn đoán mô hình là bước bắt buộc trước khi dùng volatility forecast cho VaR hoặc các quyết định quản trị rủi ro.

Các mô hình đo lường mức độ biến động khác

Các mô hình từ 2.1 đến 2.4 chủ yếu sử dụng chuỗi tỷ lệ sinh lời quá khứ. Trong thực hành, volatility còn có thể được suy ra từ giá quyền chọn hoặc đo từ dữ liệu tần suất cao. Hai nhóm thước đo này mở rộng góc nhìn của nhà phân tích: historical và GARCH volatility nhìn vào quá khứ; implied volatility phản ánh kỳ vọng thị trường; realized volatility cố gắng đo biến động đã xảy ra trong một khoảng thời gian với độ chi tiết cao hơn.

Mức độ biến động tiềm ẩn

Implied volatility là volatility được suy ra từ giá quyền chọn. Nếu ta có giá quyền chọn thị trường C^{mkt} và một mô hình định giá quyền chọn như Black–Scholes, implied volatility σ_{IV} là nghiệm của phương trình:

$$C^{mkt} = C^{BS}(S, K, r, T, \sigma_{IV}),$$

trong đó S là giá tài sản cơ sở, K là giá thực hiện, r là lãi suất phi rủi ro và T là thời gian đến đáo hạn. Khác với historical volatility, implied volatility là thước đo hướng về tương lai (*forward-looking*). Nó phản ánh mức volatility mà thị trường quyền chọn đang định giá vào tài sản cơ sở [Tsay2013; Brooks2019].

Implied volatility có vai trò quan trọng trong các thị trường phát triển vì quyền chọn được giao dịch sâu và thanh khoản. Tuy nhiên, implied volatility phụ thuộc vào mô hình định giá

quyền chọn và có thể bị ảnh hưởng bởi cung cầu quyền chọn, rủi ro thanh khoản và cấu trúc kỳ hạn. Với các thị trường mà quyền chọn chỉ số hoặc quyền chọn cổ phiếu chưa phát triển, nhà phân tích thường không có dữ liệu implied volatility đáng tin cậy. Khi đó, historical volatility, EWMA, GARCH và range-based volatility trở thành các lựa chọn thực tế hơn.

Mức độ biến động thực tế

Realized volatility đo biến động đã xảy ra bằng cách cộng các bình phương tỷ lệ sinh lời trong một khoảng thời gian. Nếu một ngày giao dịch được chia thành M khoảng nhỏ và $r_{t,j}$ là tỷ lệ sinh lời trong khoảng thứ j của ngày t , realized variance được tính bằng:

$$RV_t = \sum_{j=1}^M r_{t,j}^2.$$

Realized volatility là căn bậc hai của realized variance:

$$\sqrt{RV_t}.$$

Ưu điểm của realized volatility là sử dụng nhiều thông tin hơn tỷ lệ sinh lời đóng cửa–đóng cửa. Khi có dữ liệu intraday chất lượng cao, realized volatility thường là proxy hữu ích cho volatility thực tế và được dùng trong đánh giá dự báo volatility. Tuy nhiên, dữ liệu tần suất cao cũng có vấn đề riêng, như nhiễu vi mô thị trường (*microstructure noise*), bid–ask bounce, giao dịch không đồng bộ và lỗi ghi nhận dữ liệu [Tsay2013; Tsay2010].

Hình Figure 7 minh họa realized volatility bằng dữ liệu intraday mô phỏng. Trong dữ liệu thực tế, realized volatility thường được dùng làm proxy cho volatility không quan sát được khi đánh giá độ chính xác của các mô hình forecast volatility.

Khi không có dữ liệu intraday nhưng có dữ liệu Open–High–Low–Close, có thể dùng các thước đo range-based volatility. Ví dụ, Parkinson variance sử dụng giá cao nhất và thấp nhất trong ngày [Parkinson1980]:

$$\sigma_{P,t}^2 = \frac{1}{4 \log(2)} \left[\log \left(\frac{H_t}{L_t} \right) \right]^2.$$

Garman–Klass variance sử dụng thêm giá mở cửa và đóng cửa [GarmanKlass1980]:

$$\sigma_{GK,t}^2 = 0.5 \left[\log \left(\frac{H_t}{L_t} \right) \right]^2 - (2 \log 2 - 1) \left[\log \left(\frac{C_t}{O_t} \right) \right]^2.$$

Realized volatility sử dụng thông tin trong ngày

Ví dụ mô phỏng cho thấy realized volatility có thể theo sát trạng thái biến động khi dữ liệu intraday




Figure 7: Minh họa realized volatility từ dữ liệu intraday mô phỏng

Các thước đo OHLC hữu ích khi dữ liệu intraday khó tiếp cận nhưng dữ liệu giá mở cửa, cao nhất, thấp nhất và đóng cửa có sẵn. Trong Chương 3, các thước đo này có thể được dùng như proxy để so sánh dự báo volatility của rolling volatility, EWMA và GARCH-type models.

Nhóm thước đo	Dữ liệu cần	Hướng nhìn	Vai trò thực nghiệm
Historical/Rolling	Giá đóng cửa	Quá khứ	Benchmark
EWMA	Giá đóng cửa	Quá khứ có trọng số	RiskMetrics
GARCH-type	Tỷ lệ sinh lời	Có điều kiện	Forecast volatility
Implied volatility	Quyền chọn	Kỳ vọng thị trường	Forward-looking
Realized volatility	Intraday	Biến động đã xảy ra	Proxy đánh giá forecast
Range-based	OHLC	Biến động trong ngày	Proxy khi thiếu intraday

Tóm lược chương

Chương này đã trình bày hệ thống các phương pháp đo lường và mô hình hóa volatility theo logic từ đơn giản đến nâng cao. Historical volatility và rolling volatility trực quan, dễ tính, nhưng có hạn chế về phản ứng với thay đổi trạng thái. EWMA cải thiện bằng cách gán trọng số lớn hơn cho thông tin gần hiện tại, nhưng vẫn thiếu cơ chế mean reversion rõ ràng. ARCH và GARCH đưa volatility vào một cấu trúc phương sai có điều kiện, cho phép mô hình hóa volatility clustering và dự báo volatility. Các biến thể như IGARCH, GARCH-M, EGARCH, GJR-GARCH, TGARCH và APARCH mở rộng GARCH chuẩn để xử lý persistence cao, quan hệ rủi ro-lợi suất và bất đối xứng.

Bên cạnh các mô hình dựa trên tỷ lệ sinh lời quá khứ, implied volatility và realized volatility cung cấp hai hướng tiếp cận bổ sung. Implied volatility phản ánh kỳ vọng thị trường từ giá quyền chọn, còn realized volatility sử dụng dữ liệu tần suất cao để đo biến động đã xảy ra. Chương 3 sẽ sử dụng khung phương pháp này để đo lường, dự báo và so sánh volatility của VN-Index.